

融合多类型深度迁移学习评估电力系统暂态稳定

华中科技大学计算机科学与技术学院 CS2208 班 U202215614 王天睿

摘要: 针对单一模型泛化能力不足以及电力系统运行工况发生较大变化时暂态稳定评估模型性能下降的问题, 为了提高深度学习模型评估性能的稳定性和自适应能力, 本文提出一种融合多类型深度迁移学习模型 (tmDLM) 的评估方法, 该方法融合了深度置信网络、卷积神经网络以及长短期记忆网络 3 种不同的深度学习模型。将该方法在新英格兰 10 机 39 节点系统上进行仿真验证, 发现融合不同类型深度学习模型可以充分发挥各类模型的优势, 从而提高暂态稳定评估输出结果的稳定性。所提融合模型在判稳的同时进行稳定裕度 / 失稳程度等级的评估, 输出信息多样化, 有效缩短了模型的预测和评估时间。融合 tmDLM 可以有效跟踪系统的运行方式或拓扑结构的变化, 且可以在结构和规模完全不同的系统之间进行迁移。通过模型的迁移和有限的微调, 模型在目标域的评估精度和更新速度都得到大幅提高, 实现了电力系统暂态稳定的自适应评估。

关键词: 深度学习; 集成学习; 迁移学习; 电力系统

Abstract: Aiming at the problem of insufficient generalization ability of single model and the performance decline of transient stability assessment model when the operation condition of power system changes greatly, in order to improve the stability and adaptability of deep learning model assessment performance, this paper proposes an assessment method fusing multiple types of deep transfer learning models (tmDLM), which fuses three different deep learning models: deep belief network, convolutional neural network and long short-term memory network. The method is verified by simulation on the New England 10-machine 39-node system. It is found that fusing different types of deep learning models can give full play to the advantages of each type of model, thus improving the stability of the output results of transient stability assessment. The proposed fusion model evaluates the stability margin/instability degree level while determining stability, and the output information is diversified, which effectively shortens the prediction and assessment time of the model. The fusion of tmDLM can effectively track the changes in the operation mode or topology structure of the system, and can be migrated between systems with completely different structure and scale. Through the model migration and limited fine-tuning, the evaluation accuracy and update speed of the model in the target domain are greatly improved, realizing the adaptive evaluation of power system transient stability.

Keyword: deep learning; ensemble learning; transfer learning; electric power systems;

1. 引言

研究表明, 大停电事故的开端往往伴随着暂态稳定的破坏。现代电网规模的不断扩大、新能源接入比例的不断提高, 都对电力系统的安全稳定运行提出了新的挑战。

现有的暂态稳定评估 (transient stability assessment, TSA) 方法主要有直

接法、时域仿真法和机器学习法。直接法计算速度快, 但面对复杂电网时很难确定能量函数。时域仿真法是最成熟的 TSA 方法, 其计算精度高, 但其求解速度慢。与传统的 TSA 方法相比, 机器学习法从模式识别的角度出发, 弥补了直接法难以寻找能量函数的缺点, 无需构造复杂的数学解析模型, 通过离线学习建立系统特征量与暂稳态预测输出结果间的隐式

映射关系,在实际在线应用时,利用学习到的映射关系可快速得出稳定评估结果。常用的浅层学习方法主要有支持向量机(support vector machine, SVM)、决策树(decision tree, DT)、随机森林 random forest, RF)等。由于浅层学习方法对数据挖掘分析的能力有限,在线应用时其泛化能力受到限制。

近年来,随着深度学习方法的快速发展以及由于深度学习方法在特征提取方面的优越性能,其在人脸识别、自然语言处理等领域广泛应用。在电力系统领域中用途也同样广泛。

本报告涉及关键点是将深度学习、迁移学习和故障后的暂态功角稳定评估相结合。^[1]

该关键点属于人工智能的连接主义流派(connectionism),在课堂 PPT 中对应的描述为“以数据为驱动核心的机器学习”。目前处于连接主义流派的鼎盛期。例如目前热度最高的大语言模型 chatGPT 就是属于自然语言处理(NLP)领域的成果,而 NLP 是连接主义流派的一员。

2. 国内外发展现状分析

(以下按照“某人/团队,针对 xxx 问题,提出 xxx 方法、实现 xxx 关键技术点,达到 xxx 效果”格式描述)

在电力系统 TSA 领域:2018 年朱乔木团队等人提出一种基于深度置信网络(deep belief network, DBN)的 TSA 方法^[2],利用深层架构对系统特征与稳定结果之间的映射关系进行训练;2019 年高昆仑团队提出一种基于一维卷积神经网络(convolutional neural network, CNN)的 TSA 方法^[3],该方法直接面向底层测量数据,实现了端到端的“时序特征提取+暂态稳定分类”;2020 年李宝琴团队针对电力系统的时序特征数据,基于长短期记忆网络(long short-term memory, LSTM)算法提出一种基于滑动时间窗口的暂态稳定防抖模型^[4];2021 年卢东昊团队针对主动学习过程中选择样本的冗余度的问题,提出一种聚类自适应主动学习选择策略^[5],加快了学习进程。

虽然上述深度学习方法在电力系统 TSA 方面取得了一定的成果,但其忽略了模型的自适应更新能力。数据驱动的 TSA 过程是动态变

化的,预训练模型需要不断适应电力系统的运行方式或拓扑结构的变化,如负荷水平的大幅波动、发电机或线路的投退等。

迁移学习和深度学习的结合,可有效提升深度学习模型的泛化能力和自适应能力,目前迁移学习在电力系统暂态稳定领域的应用尚处于探索阶段。

2019 年张若愚团队基于 CNN,利用新生成的最小平衡样本集训练分类层参数,从而快速得到适用于新场景的预测模型^[6]。2021 年汤奕团队将基于增量学习的深度继承和基于迁移学习的广度继承应用于暂态稳定预测问题^[7];2022 年 2 月李宝琴团队提出一种基于改进深度卷积生成对抗网络的暂态稳定增强型自适应评估方法^[8];同年 6 月,Chao 团队通过迭代最小化训练数据与未知数据之间边缘分布和条件分布的差异,将预训练模型迁移到未知的不同但相关的故障^[9]。

本文则将深度学习、迁移学习和故障后的暂态功角稳定评估相结合,提出一种适用于电力系统 TSA 的融合多类型深度迁移学习的自适应评估方法,该方法不仅可以自适应地跟踪系统拓扑结构和运行方式的变化,还可以在结构和规模不同的系统之间进行迁移,输出多样性的评估结果,大幅缩短了模型的更新训练时间,实现了电力系统暂态稳定的自适应评估。

3. 问题定义与建模

3.1 问题定义

暂态稳定预测问题属于分类问题。本文将样本分为不稳定样本、较不稳定样本、临界不稳定样本、临界稳定样本、较稳定样本、很稳定样本六大类。本文在判稳的同时进行稳定裕度和失稳程度等级的评估,有效缩短模型的离线训练和在线评估时间。

基于机器学习的暂态稳定预测是建立输入特征 X 和输出 Y 间的映射关系。原始训练数据集 $D_{pre} = \{(x_1, Y_1), \dots, (x_N, y_N)\}$ 。式中: $x_i \in X \in R$, $y_i \in \{C_1, C_2, \dots, C_m\}$ ($i = 1, 2, \dots, N$), d 为输入特征的维度, N 为样本总数, C_i ($i=1, 2, \dots, m$) 为暂态稳定预测的第 i 个类别, m 为暂态稳定预测的标签类别数。本文 $m=6$ 。

3.2 问题建模

输入数据是由相量测量单元采集的不同时刻的各类电气数据，该数据为流式数据。

针对 TSA 问题，本文分类模型的输入为发电机的功角轨迹簇特征，其不会随着系统规模和发电机台数的增加而增加，是统计特征，输入节点数始终是 27，为不同系统间基于模型的迁移奠定了基础。

此外，本文所构建评估模型的输出节点数为 6，在判稳的同时进行稳定裕度和失稳程度等级的评估。

3.3 暂态稳定程度评估

本文采用从故障切除到系统发生失稳所经历的时间 B 来评估样本的失稳程度。

$B_s \in [0, 1]$, $Bus \in [0, 5]$, B_s 越小，系统的稳定裕度越小， Bus 也越小，系统的失稳程度越严重。

计算方法如下：

$$S = \int_0^t (\max \varphi_h - \min \varphi_h) dt \quad (1)$$

$$B_s = \frac{S_{\max} - S}{S_{\max} - S_{\min}} \quad (2)$$

$$B_{us} = t_{us} - t_{cl} \quad (3)$$

式中： φ_h 为第 h 台发电机的转子角；t 为仿真时间； S_{\max} 、 S_{\min} 分别为受扰程度 S 的最大值和最小值； t_{us} 为系统发生失稳（即任意 2 台发电机的转子角超过 360 度）的时刻， t_{cl} 为故障切除的时刻。

具体数值对应如下表。

表 1 暂态稳定多级指标划分对应表

类别	编号	指标范围 (Bus 单位: s)	程度等级
失稳类	1	$0 \leq Bus < 0.5$	不稳定
	2	$0.5 \leq Bus < 1$	较不稳定
	3	$1 \leq Bus < 5$	临界不稳定
稳定类	4	$0 \leq Bs < 0.6$	临界稳定
	5	$0.6 \leq Bs < 0.8$	较稳定
	6	$0.8 \leq Bs \leq 1$	很稳定

4. 问题求解与实现算法

4.1 评估矩阵

用六分类的数据集来构造多类型的深度学习评估模型，评估结果可以表示为评估结果矩阵 $R = (r_{ij})_{6 \times 6}$ 。如下图所示。

$$R = \begin{bmatrix} r_{11} & r_{12} & r_{13} & r_{14} & r_{15} & r_{16} \\ r_{21} & r_{22} & r_{23} & r_{24} & r_{25} & r_{26} \\ r_{31} & r_{32} & r_{33} & r_{34} & r_{35} & r_{36} \\ r_{41} & r_{42} & r_{43} & r_{44} & r_{45} & r_{46} \\ r_{51} & r_{52} & r_{53} & r_{54} & r_{55} & r_{56} \\ r_{61} & r_{62} & r_{63} & r_{64} & r_{65} & r_{66} \end{bmatrix}$$

图 1 评估矩阵

其中 r_{ij} 表示实际为第 i 类而预测为第 j 类的样本数。

4.2 评估指标

定义： T_s 、 T_u 。分别表示稳定样本和失稳样本正确识别的数目，分别对应评估矩阵后 3 行的右半部分、前 3 行的左半部分； F_{us} 表示将稳定样本误判为失稳样本的样本数，对应评估矩阵后 3 行的左半部分； F_s 表示将失稳样本漏判为稳定样本的样本数，对应评估矩阵前 3 行的右半部分。

构造 5 个指标：

- 1) 评估准确率 A_{eval} , 即正确评估稳定程度等级的样本占所有样本的比例

$$A_{eval} = \sum_{i=1}^6 \frac{r_{ij}}{T_s + T_{us} + F_s + F_{us}} \quad (4)$$

- 2) 判稳准确率 A_{cc} , 即正确预测稳定 / 失稳的样本占所有样本的比例

$$A_{cc} = \frac{T_s + T_{us}}{T_s + T_{us} + F_s + F_{us}} \quad (5)$$

- 3) 安全性 S_e , 即正确预测稳定的样本占所有稳定样本的比例

$$S_e = \frac{T_s}{T_s + F_{us}} \quad (6)$$

- 4) 可靠性 R_e , 即正确预测失稳的样本占所有失稳样本的比例

$$R_e = \frac{T_{us}}{T_{us} + F_s} \quad (7)$$

- 5) 可靠性和安全性的几何平均数 G_e 与 A_{cc} 相比, G 值能够客观反映模型对失稳样本的预测性能。

$$G = \sqrt{R_e S_e} \quad (8)$$

4.3 实现算法: 融合迁移学习的多类型深度学习模型

共分为三个步骤: 原模型训练, 目标域迁移, 模型融合

具体的过程如下:

- 1) 原模型训练

使用时域仿真生成的源域预训练数据集 D_{pre} 训练原模型 $M_{pre}(x)$, 并保存 $M_{pre}(x)$ 的参数, 如式(9)所示。

$$M_{pre}(x) = PreTrain(D_{pre}) \quad (9)$$

式中: $PreTrain(\cdot)$ 表示预训练过程。

- 2) 目标域迁移

迁移预训练得到的原模型 $M_{pre}(x)$ 的结构和参数, 在目标域数据集 D 上自适应地调整网络参数, 得到适用于目标域的 TSA 模型 $M(x)$, 如式(10)所示。

$$M(x) = Transfer(M_{pre}(x), D) \quad (10)$$

式中: $Transfer(\cdot)$ 表示迁移更新过程。

目标域迁移的具体步骤如下(本文的迁移过程是一个不断迭代的过程, 采用蒙特卡罗法

针对目标域的运行方式或拓扑结构生成少量的样本, 设初始迁移样本库 D_m 为空集):

1. 首先从目标域样本集中随机筛选 N_m 个样本放入 D_m 中, 并从训练集中将这些样本删除。
2. 利用 D_m 对原模型 M_0 进行迁移学习, 得到新模型 M_1 。
3. 重复以上步骤, 每次迭代筛选 N_m 个样本, 对上一次的模型进行更新微调, 直到模型对新场景下的测试集预测准确率达到预设值或迭代过程中模型性能不再提升, 此时得到更新后的模型 M_{new} 。在迁移更新的过程中, 一般在 3—5 次迭代后模型性能可得到有效恢复, 大幅减少了目标域所需的样本数量。

上述步骤可以总结为下图。

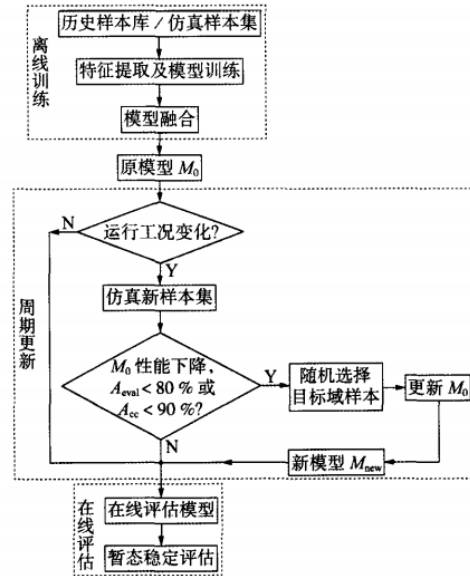


图2 自适应评估流程

- 3) 模型融合

将迁移后的多类型深度学习模型融合为一个适用于系统当前运行工况和拓扑结构的 TSA 模型。值得说明的是, 本文所提融合多类型深度迁移学习方法是一种基于模型的迁移, 模型迁移的过程中只需保证源域和目标域的输入、输出维度一致即可。针对 TSA 问题, 本文分类模型的输入为发电机的功角轨迹簇特征, 其不会随着系统规模和发电机台数的增加而增加, 是统计特征, 输入节点数始终是 27, 为不同系统间基于模型的迁移奠定了基础。此外, 本文所构建评估模型的输出节点数为 6, 在判稳的同时进行稳定裕度和失稳程度等级

的评估。因此，源域和目标域系统的输入、输出维度完全一致，可以在结构和规模不同的系统间进行迁移。

5、实现结果分析

5.1 新英格兰 10 机 39 节点系统测试结果

新英格兰 10 机 39 节点系统中包含 10 台发电机、39 条母线、12 台变压器和 34 条交流线路，额定频率为 60 Hz。采用电力系统仿真软件(power system toolbox, PST)3.0 生成暂态稳定样本集。为了构造较为完备的样本空间，考虑系统的常规变化，设置负荷水平为基准负荷的 75%~120%，以 5%为步长，相应地调整发电机出力以保证潮流收敛。在 34 条输电线路路上设置最为严重的三相短路故障，故障位置设置在每条输电线路全长的 0~90%处，以 10%为步长。故障切除时间设置为故障后的 1—11 个周期，以 1 个周期(即 0.0167 s)为步长。仿真时间为 5 S，共生成 37400 个样本，按 4: 1 的比例将样本随机划分为训练集和测试集。

为了验证本文所提融合 mDLM 的性能优势以及融合的必要性，将 mDLM 与基分类器 DBN、LSTM、CNN 以及浅层学习中的 SVM、DT、K 近邻(K nearest neighbor, KNN)进行对比分析。针对以上各分类器，分别选择最优参数。本文各类深度学习模型数 $n'=1$ ，采用逐层寻优的方式确定性能良好的结构。DBN 的结构为 81—200—100—50—30—6，受限玻尔兹曼机(restricted Boltzmann machine, RBM)重构的学习率为 0.8；CNN 由输入层、2 对卷积层和池化层、全连接层及分类层组成，其中卷积层的大小为 3x3，池化层的大小为 2x2，全连接层的节点数为 1 000，本文直接将暂态稳定样本集分为 6 类，因此分类层的节点数为 6；LSTM 的结构设置和 DBN 的相同，mDLM 的各基分类器均采用 Adam 优化算法，初始学习率为 0.001，训练样本数为 187；SVM 的核函数为径向基函数，采用网格法和五折交叉

验证对参数进行寻优；DT 采用 C5.0 算法；KNN 经寻优后的最近邻数后=18。
测试结果如下表。

表 2 不同模型的测试结果

模型	评价指标				
	$A_{eval}/\%$	$A_{cc}/\%$	$S_e/\%$	$R_e/\%$	$G/\%$
mDLM	92.31	98.33	99.09	97.17	98.13
DBN	91.69	98.14	98.69	96.92	97.80
LSTM	90.32	96.84	96.18	97.35	96.86
CNN	91.32	98.18	99.01	96.67	97.83
SVM	80.59	94.43	95.54	92.67	94.11
DT	80.32	94.30	95.54	92.43	93.67
KNN	77.21	94.01	96.83	89.74	93.22

由表 2 可知：相较于 SVM、DT、KNN，mDLM 的评估准确率 A_{eval} 分别高 11.72%、11.99%、15.10%，判稳准确率 A_{cc} ，分别高 3.90%、4.03%、4.32%，这说明 mDLM 凭借各类深度学习模型强大的特征提取和数据挖掘能力，能够有效地拟合电力系统输入特征和暂态稳定输出结果之间的非线性映射关系，从而获得比浅层学习更加优越的评估性能；相较于基分类器 DBN、LSTM、CNN，mDLM 的评估准确率 A_{eval} 分别高 0.62%、1.99%、0.99%，判稳准确率 A_{cc} 分别高 0.19%、1.49%、0.15%，这说明 mDLM 能够取长补短，其评估性能要优于任意一个基分类器。

5.2 迁移效果分析

为生成与初始训练集分布差异较大且不在模型泛化能力范围内的新样本，以验证迁移学习的有效性，将系统负荷水平分别调整至基准负荷的 135%、140%、145%、150%，并相应调节发电机的出力，使得潮流计算收敛。仿真共生成 14960 个样本，包括 3183 个稳定样本和 11 777 个失稳样本。将超负荷样本集按 1: 1 的比例划分为训练集和测试集。先前训练好的源域 mDLM 在超负荷水平样本集上的测试结果如表 3 所示。

表 3 迁移学习超负荷水平的测试结果

数据集	A_{eval} /%	A_{cc} /%	S_e /%	R_e /%	G /%
训练集	62.53	90.01	94.05	88.95	91.46
测试集	62.67	90.07	93.33	89.17	91.22

由表 3 可知, 原 mDLM 在超负荷水平下的评估性能下降较多, 尤其是评估准确率 A_{eval} 和对失稳样本的识别率 R_e 分别低于 65% 和 90%, 评估性能大幅下降, 模型无法进行在线应用, 因此需在该超负荷场景下对模型进行迁移更新。采用方案 3, 每次筛选的样本数 $N_m=187$, 分别从训练样本集中选择 187、374、561、...、7480 个样本对原模型进行迁移。迁移更新后的 mDLM 以 tmDLM 表示, 迁移后的各基分类器分别表示为 tDBN、tCNN、tLSTM, 更新后的评估准确率 A_{eval} 和判稳准确率 A_{cc} 。分别如图 3 (a) (b) 所示。

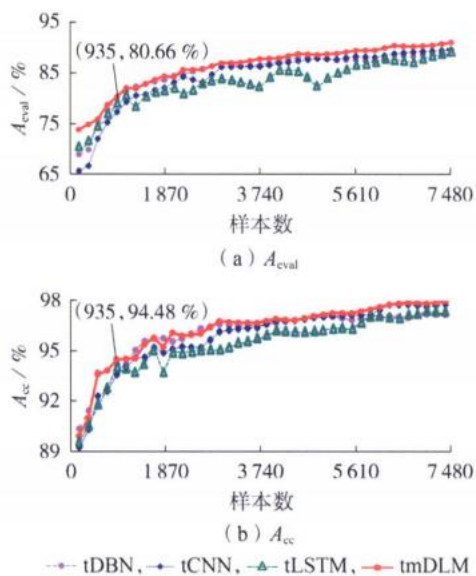


图 3 超负荷水平下各基分类器的迁移效果

由图 3 可知, 所选择的迁移样本数越多, 迁移效果越好, 模型在迁移初期性能恢复越快。本文所提融合 tmDLM 方法的迁移效果优于任意一个基分类器。当用于迁移的样本数 $D_m=935$ 时, 评估准确率 A_{eval} 从初始的 62.67% 恢复至 80.66%, 判稳准确率 A_{cc} 从初始的 90.07% 恢复至 94.48%, 这说明融合 tmDLM

方法仅利用较少的目标域样本集对源域模型进行迁移更新, 即可快速得到适用于系统当前运行工况的模型, 从而验证了该方法的有效性。

为分析所提方法在迁移更新过程中所需样本数的优势, 将其和基分类器 tDBN、tCNN、tLSTM 进行对比。当评估准确率 A_{eval} 恢复到 85% 时, tmDLM 和各基分类器的判稳准确率 A_{cc} 均恢复到 95% 以上, 此时融合模型所需的样本数为 1870, 而基分类器 tDBN、tCNN、tLSTM 在达到相同精度时所需的样本数分别为 2244、2992、4114, 因此本文所提方法相比单一的深度迁移学习算法, 在训练到相同精度时所需的样本数更少, 缩短了样本生成和迁移更新的时间, 有利于进行在线连续的暂态稳定自适应评估。

6、总结展望与思考

6.1 论文总结与思考

针对单一模型泛化能力不足以及电力系统运行工况发生较大变化时 TSA 模型性能下降的问题, 为了提高深度学习模型评估性能的稳定性和自适应能力, 本文提出一种融合 tmDLM 的评估方法, 在新英格兰 10 机 39 节点系统上进行仿真验证, 得到如下结论。

1) 融合不同类型深度学习模型可以充分发挥各类模型的优势, 从而提高 TSA 输出结果的稳定性。所提融合模型在判稳的同时进行稳定裕度 / 失稳程度等级的评估, 输出信息多样化, 有效缩短了模型的预测和评估时间。

2) 融合 tmDLM 可以有效跟踪系统的运行方式或拓扑结构的变化, 且可以在结构和规模完全不同的系统之间进行迁移。通过模型的迁移和有限的微调, 模型在目标域的评估精度和更新速度都得到大幅提高, 实现了电力系统暂态稳定的自适应评估。

对调度人员无法预知的紧急变化情况, 针对新的拓扑结构快速生成最少量且最富有信息的样本并对模型进行在线迁移更新, 以及进一步考虑增加融合的学习方法对整体评估效果的影响, 将是下一步研究工作的重点。

6.2 课程总结与思考

《人工智能导论》这门课面向像我一样的初学者十分友好,老师的讲述主要为我们灌输人工智能的概念和思想,并未引入太多定量实践使得课程晦涩难懂。我在课程中引发了对人工智能的兴趣。

本报告主要部分于考试周抽空完成,因此可能有所缺陷,敬请谅解。

完成此报告我查阅了诸多资料,对人工智能的各种流派都有了更深的理解。尤其是本报告核心的多类型深度迁移学习,融合了深度学习、迁移学习、自适应评估和电力相关知识。

在第5节介绍他人实验结果时,我发现他人的实验结果有三点优点值得我学习。一是任何举动都考虑周到,其他无关环境参数详细,结果数据翔实;二是任何结果都有和当下其他基分类器同样实验结果比较,由此进一步增加说服力。

本报告的完成离不开我的个人努力,更离不开老师的谆谆教诲,感谢该门课程教授我的莫益军老师!

【参考文献】

- [1]李宝琴,吴俊勇,张若愚,等. 融合多类型深度迁移学习的电力系统暂态稳定自适应评估[J]. 电力自动化设备, 2023,43(1):184-192.DOI:10.16081/j.epae.202206002.
- [2]朱乔木,党杰,陈金富,等. 基于深度置信网络的电力系统暂态稳定评估方法[J]. 中国电机工程学报, 2018,38(3):735-743, 后插 8. DOI:10.13334/j.0258-8013.pcsee.162436.
- [3] 高昆仑,杨帅,刘思言,等. 基于一维卷积神经网络的电力系统暂态稳定评估[J]. 电力系统自动化, 2019,43(12):18-26. DOI:10.7500/AEPS20180911006.
- [4] Baoqin Li,Junyong Wu,Liangliang Hao,等.Anti-Jitter and Refined Power System Transient Stability Assessment Based on Long-Short Term Memory Network[J].IEEEAccess.2020.835231-35244.DOI:10.1109/ACCESS.2020.2974915
- [5] 卢东昊,王莉,张少凡,等. 基于聚类自适应主动学习的电力系统暂态稳定评估[J]. 电力自动化设备, 2021,41(7):176-181. DOI:10.16081/j.epae.202105024.
- [6] 张若愚,吴俊勇,李宝琴,等.基于迁移学习的电力系统暂态稳定自适应预测[J]. 电网技术.2020,(6).2196-2205.DOI:10.13335/j.1000-3673.pst.2019.2376 .
- [7] 汤奕,崔晗,党杰.基于继承思想的时变性电力系统暂态稳定预测[J]. 中国电机工程学报. 2021,(15).5107-5119.DOI:10.13334/j.0258-8013.pcsee.200829 .
- [8] 李宝琴,吴俊勇,强子玥,等. 基于改进 DCGAN 的电力系统暂态稳定增强型自适应评估[J]. 电力系统自动化, 2022,46(2):73-82. DOI:10.7500/AEPS20210402007.
- [9] REN, CHAO, XU, YAN. Transfer Learning-Based Power System Online Dynamic Security Assessment: Using One Model to Assess Many Unlearned Faults[J]. 2020,35(1):821-824. DOI:10.1109/TPWRS.2019.2947781.